

Co se změní, když přidáme prediktor?

Vícenásobný lineární model na klimatických datech křídlatky

23. srpna 2026

Obsah

1	Mění klima původu tloušťku listů křídlatky?	1
2	Co se v této lekci naučíme	2
3	Křídlatky z různých částí světa ve společné zahradě	2
4	Populace z teplejších oblastí mají v průměru tenčí listy	9
5	První model používá jednu klimatickou informaci	9
5.1	Odpovídá přímka struktuře reziduí?	11
6	Lineární model může skládat několik příspěvků	12
7	Klimatické proměnné nenesou nezávislé informace	16
8	Porovnání modelů	19
8.1	Změnil druhý prediktor také strukturu reziduí?	20
9	Původ populací mění příběh vztahu	21
9.1	Kontrola modelu s teplotou a původem	24
10	Jak model odhadne tloušťku při stejné teplotě	26
11	Stejně porovnání doplníme o nejistotu	29
12	Záleží u testu na pořadí prediktorů?	32
12.1	Co se změní v tabulce koeficientů?	32
12.2	Sekvenční analýza rozptylu klade otázky zleva doprava	33
12.3	Výběr prediktorů patří do dalších lekcí	36
13	Jak postupovat u modelu s více prediktory	36
14	Společná zahrada neznamena náhodně přiřazené klima	36
15	Co si odnést	37

1 Mění klima původu tloušťku listů křídlatky?

V předchozích lekcích jsme fitovali lineární model s jedním prediktorem. Číselný prediktor popisoval změnu podél gradientu a kategoriální prediktor rozdíl mezi skupinami. Mnohé biologické otázky však potřebují zohlednit několik charakteristik současně.

Budeme sledovat křídlatku japonskou (*Reynoutria japonica*). Rostliny pocházely z populací v původním i zavlečeném areálu a byly pěstovány ve společných zahradách. Ptáme se:

Otázka lekce

Jak souvisí tloušťka listu s klimatem místa, odkud populace pochází, a co se stane s odhadem, když do modelu přidáme další související prediktory?

2 Co se v této lekci naučíme

Po této lekci dokážeme:

- zapsat a fitovat lineární model s několika prediktory;
- interpretovat koeficient „při stejných hodnotách ostatních prediktorů“;
- vysvětlit, proč se odhad koeficientu po přidání prediktoru změní;
- rozpoznat korelaci prediktorů a překrývající se informaci;
- porovnat skupiny po zohlednění číselného prediktoru;
- vytvářet predikce jen pro smysluplné kombinace prediktorů;
- rozlišit p-hodnotu testu koeficientu od pořadím ovlivněného sekvenčního testu prediktoru.

3 Křídlatky z různých částí světa ve společné zahradě

Zdrojová data pocházejí ze studie Cao et al. (2025). Autoři odebrali oddenky populací z Číny, Japonska, Evropy a Severní Ameriky a pěstovali je ve dvou společných zahradách v Číně. V lekci používáme zahradu v Šanghaji.

U každé populace zprůměrujeme tloušťku listů jejích rostlin. Jeden řádek výukové tabulky proto představuje **jednu zdrojovou populaci**, nikoli jednu rostlinu. Klimatické prediktory popisují místo původu populace.

Klimatická data pocházejí z otevřeného souboru CHELSA-BIOCLIM 2.1, který shrnuje dlouhodobou teplotu, srážky, sezónnost a klimatické extrémy za období 1981–2010. Zdrojová data mají technické kódy, ale ve výukové tabulce používáme popisné české názvy.

Doplňující: stažení a příprava dat

Pro běžnou práci používáme hotovou lokální tabulku, takže není potřeba internetové připojení. Volitelný postup níže umožňuje celý vznik tabulky zopakovat: stáhne původní znaky z repozitáře Dryad, ověří soubor, získá klimatická data CHELSA a spojí oba zdroje. Jednotlivé rostliny shrneme na úroveň populace, protože klima se mezi rostlinami stejné populace nemění. Pokud automatické stažení z Dryad selže, stáhněte soubor herb-trait.csv ze [stránky datasetu](#) ručně do složky data-raw; kontrolní součet v kódu ověří správnou verzi.

```
install.packages(pkgs = c("digest", "here", "terra"))

# 1. Připravíme adresáře pro stažená a výsledná data
soubor_znaky <- here::here("data-raw", "herb-trait.csv")
soubor_vyuka <- here::here("data", "kridlatka_populace.csv")
```

```

dir.create(path = dirname(path = soubor_znaky), recursive = TRUE,
showWarnings = FALSE)
dir.create(path = dirname(path = soubor_vyuka), recursive = TRUE,
showWarnings = FALSE)

# 2. Stáhneme původní tabulku znaků přímo z Dryad
url_znaky <- "https://datadryad.org/downloads/file_stream/3893167"

if (!file.exists(soubor_znaky)) {
  download.file(
    url = url_znaky,
    destfile = soubor_znaky,
    mode = "wb"
  )
}

# Kontrolní součet odhalí neúplné nebo později změněné stažení
sha256_cekavany <- paste0(
  "c6a5afae067597870156fc1fe4b8e688",
  "3784d5eb40f967a2ca95dde6d4fc74a8"
)

sha256_stazeny <- digest::digest(
  object = soubor_znaky,
  algo = "sha256",
  file = TRUE
)

stopifnot(identical(x = sha256_stazeny, y = sha256_cekavany))

# 3. Načteme tabulku a dáme sloupcům krátké pracovní názvy
znaky <- read.csv(
  file = soubor_znaky,
  check.names = FALSE
)

names(znaky) <- c(
  "garden", "range", "population", "individual", "latitude", "longitude",
  "block", "root_weight_g", "source", "leaf_thickness_mm",
  "leaf_toughness_n", "leaf_cn", "alkaloids_mg_g", "flavonoids_mg_g",
  "lignin_mg_g", "herb_beetle_pct", "herb_caterpillar_pct"
)

```

```

# 4. Vybereme šanghajskou zahradu a vytvoříme průměr za populaci
znaky_shanghai <- znaky[znaky$garden == "SH", ]

populace <- aggregate(
  x = leaf_thickness_mm ~ population + range + source + latitude + longitude,
  data = znaky_shanghai,
  FUN = mean
)

# 5. Otevřeme osm vrstev CHELSA-BIOCLIM 2.1 (1981–2010)
vybrane_bioclim <- c(
  "bio1", "bio4", "bio5", "bio6",
  "bio12", "bio13", "bio14", "bio15"
)

zaklad_klima <- paste0(
  "https://os.zhdk.cloud.switch.ch/chelsav2/GLOBAL/",
  "climatologies/1981-2010/bio/"
)

Sys.setenv(
  GDAL_DISABLE_READDIR_ON_OPEN = "YES",
  CPL_VSIL_CURL_ALLOWED_EXTENSIONS = ".tif"
)

adresy_vrstev <- paste0(
  "/vsicurl/", zaklad_klima, "CHELSA_", vybrane_bioclim,
  "_1981-2010_V.2.1.tif"
)

# 6. Z vrstev vyzvedneme klima v souřadnicích každé populace
body_populaci <- terra::vect(
  x = populace,
  geom = c("longitude", "latitude"),
  crs = "EPSG:4326"
)

klima_populaci <- lapply(
  X = adresy_vrstev,
  FUN = function(adresa) {
    vrstva <- terra::rast(x = adresa)
    terra::extract(x = vrstva, y = body_populaci, ID = FALSE)[[1]]
  }
)

klima_populaci <- as.data.frame(klima_populaci)

```

```

names(klima_populaci) <- vybrane_bioclim

# 7. Spojíme znaky s osmi vybranými BIOCLIM proměnnými
data_vyuka <- cbind(populace, klima_populaci)

# 8. Použijeme stejné české názvy a kódování původu jako v lekci
names(data_vyuka) <- c(
  "populace", "oblast", "puvod", "zemepisna_sirka", "zemepisna_delka",
  "tloustka_listu_mm", "teplota_rocni_C", "teplota_sezonnost",
  "teplota_max_C", "teplota_min_C", "srazky_rocni_mm",
  "srazky_nejvlhci_mesic_mm", "srazky_nejsussi_mesic_mm",
  "srazky_sezonnost"
)

data_vyuka$puvod <- ifelse(
  test = data_vyuka$puvod == "Native",
  yes = "Puvodni",
  no = "Zavleceeny"
)

data_vyuka <- data_vyuka[order(data_vyuka$populace), ]

# 9. Před uložením ověříme očekávaný počet a úplnost dat
stopifnot(
  nrow(x = data_vyuka) == 128,
  !anyNA(x = data_vyuka),
  abs(x = cor(x = data_vyuka$teplota_rocni_C, y = data_vyuka$teplota_max_C)
- 0.855) < 0.002
)

write.csv(
  x = data_vyuka,
  file = soubor_vyuka,
  row.names = FALSE,
  na = ""
)

```

Původní tabulka z Dryad má přibližně 121 kB. Osm vrstev CHELSA-BIOCLIM čteme po malých úsecích přímo ze vzdálených souborů, takže postup vyžaduje internetové připojení a může několik minut běžet. Vrstva má rozlišení 30 úhlových sekund (přibližně 1 km). Studie Cao et al. použila jiný klimatický zdroj; naše výukové hodnoty proto nejsou kopií klimatické tabulky studie.

Zdroj znaků: Cao et al. (2025), Dryad, CC0, DOI [10.5061/dryad.qbzh18r4](https://doi.org/10.5061/dryad.qbzh18r4). Klimatické vrstvy: [CHELSA-BIOCLIM 2.1](#), období 1981–2010, CC0; Brun et al. (2022), DOI [10.16904/envidat.332](https://doi.org/10.16904/envidat.332).

Připravenou tabulku načteme bez stahování klimatických vrstev:

```
data_kridlatka <- read.csv(
  file = here::here("data", "kridlatka_populace.csv")
)

data_kridlatka$puvod <- factor(
  x = data_kridlatka$puvod,
  levels = c("Puvodni", "Zavle ceny")
)
```

Z celé tabulky vybereme sloupce, které budeme opakovaně používat. Souhrn ukáže typické hodnoty, rozsahy a případné chybějící údaje:

```
data_kridlatka_pracovni <- data_kridlatka[c(
  "populace", "puvod", "tloustka_listu_mm",
  "teplota_rocni_C", "teplota_sezonnost", "teplota_max_C",
  "teplota_min_C", "srazky_rocni_mm",
  "srazky_nejvlhci_mesic_mm", "srazky_nejsussi_mesic_mm",
  "srazky_sezonnost"
)]

summary(object = data_kridlatka_pracovni)
```

populace	puvod	tloustka_listu_mm	teplota_rocni_C
Length:128	Puvodni :55	Min. :0.2922	Min. : 5.95
Class :character	Zavle ceny:73	1st Qu.:0.3353	1st Qu.: 9.25
Mode :character		Median :0.4180	Median :12.60
		Mean :0.3928	Mean :12.89
		3rd Qu.:0.4401	3rd Qu.:17.12
		Max. :0.5192	Max. :19.95
teplota_sezonnost	teplota_max_C	teplota_min_C	srazky_rocni_mm
Min. : 423.8	Min. :19.25	Min. : -14.650	Min. : 574.2
1st Qu.: 653.1	1st Qu.:23.52	1st Qu.: -3.875	1st Qu.: 832.1
Median : 719.4	Median :27.90	Median : -1.700	Median :1248.7
Mean : 747.5	Mean :27.17	Mean : -1.885	Mean :1401.2
3rd Qu.: 850.1	3rd Qu.:30.77	3rd Qu.: 1.350	3rd Qu.:1877.3
Max. :1027.4	Max. :33.95	Max. : 6.450	Max. :3217.8
srazky_nejvlhci_mesic_mm	srazky_nejsussi_mesic_mm	srazky_sezonnost	

Min. : 63.2	Min. : 6.40	Min. : 7.00
1st Qu.:100.6	1st Qu.: 41.15	1st Qu.: 13.90
Median :151.2	Median : 50.75	Median : 28.80
Mean :206.3	Mean : 54.89	Mean : 36.71
3rd Qu.:305.5	3rd Qu.: 71.50	3rd Qu.: 56.17
Max. :641.7	Max. :128.00	Max. :105.60

Význam jednotlivých sloupců je:

Sloupec	Co obsahuje	Role v analýze
populace	identifikátor zdrojové populace	jednotka pozorování
puvod	původní nebo zavlečený areál	potenciální kategoriální prediktor
tloustka_listu_mm	průměrná tloušťka listu v mm	odezva
teplota_rocni_C	průměrná roční teplota v °C	potenciální číselný prediktor
teplota_sezonnost	proměnlivost teplot během roku	potenciální číselný prediktor
teplota_max_C	maximum teploty nejteplejšího měsíce v °C	potenciální číselný prediktor
teplota_min_C	minimum teploty nejchladnějšího měsíce v °C	potenciální číselný prediktor
srazky_rocni_mm	roční úhrn srážek v mm	potenciální číselný prediktor
srazky_nejvlhci_mesic_mm	srážky nejvlhčího měsíce v mm	potenciální číselný prediktor
srazky_nejsussi_mesic_mm	srážky nejsuššího měsíce v mm	potenciální číselný prediktor
srazky_sezonnost	proměnlivost srážek během roku	potenciální číselný prediktor

Funkce `str()` doplní přesné typy hlavních proměnných. Samostatně spočítáme chybějící hodnoty a zastoupení obou areálů:

```
str(object = data_kridlatka_pracovni)
```

```
'data.frame': 128 obs. of 11 variables:
 $ populace      : chr  "CN1" "CN10" "CN11" "CN12" ...
 $ puvod         : Factor w/ 2 levels "Puvodni","Zavleceny": 1 1 1 1
```

```

1 1 1 1 1 1 ...
$ tloustka_listu_mm      : num  0.346 0.343 0.323 0.328 0.323 ...
$ teplota_rocni_C        : num  18.3 18.9 18.1 19.1 19.6 ...
$ teplota_sezonnost      : num  818 771 706 712 720 ...
$ teplota_max_C          : num  32.9 33.1 31.3 32.1 33 ...
$ teplota_min_C          : num  1.65 2.45 2.45 3.05 3.35 ...
$ srazky_rocni_mm        : num  2073 1874 2484 1906 1945 ...
$ srazky_nejvlhci_mesic_mm: num  382 325 421 323 317 ...
$ srazky_nejsussi_mesic_mm: num  52.8 46.8 60.3 45.6 47.3 43.9 37.4 38.3
41.7 42.1 ...
$ srazky_sezonnost       : num  56.5 58.1 58.4 59.6 59.2 56.6 55 54.6
54.9 56.5 ...

```

```
colSums(x = is.na(x = data_kridlatka_pracovni))
```

populace	puvod	tloustka_listu_mm
0	0	0
teplota_rocni_C	teplota_sezonnost	teplota_max_C
0	0	0
teplota_min_C	srazky_rocni_mm	srazky_nejvlhci_mesic_mm
0	0	0
srazky_nejsussi_mesic_mm	srazky_sezonnost	
0	0	

```
table(data_kridlatka$puvod)
```


Puvodni	Zavleceeny
55	73

Kontrola potvrzuje 128 populačních průměrů, číselné hodnoty očekávaného řádu a žádnou chybějící hodnotu v proměnných hlavních modelů. Rozsahy teplot zároveň vymezují podmínky, pro které jsou predikce podloženy daty.

Co je jednotkou analýzy?

Která pozorování mohou mít stejnou hodnotu klimatického prediktoru: jednotlivé rostliny ze stejné populace, nebo různé zdrojové populace? Proč by analýza všech rostlin jako nezávislých klimatických pozorování nadhodnotila množství informace?

4 Populace z teplejších oblastí mají v průměru tenčí listy



Obrázek 1: Průměrná tloušťka listu a průměrná roční teplota místa původu. Jeden bod je jedna populace pěstovaná v Šanghaji.

Co dokážeme vyčíst z grafu?

Popište směr a sílu vztahu. Jak těsně body sledují klesající směr a vidíte neobvyklá pozorování?

Graf naznačuje silný klesající vztah. Z předchozích lekcí známe korelaci, která jeho směr a těsnost shrne jedním číslem:

```
cor(  
  x = data_kridlatka$teplota_rocni_C,  
  y = data_kridlatka$tloustka_listu_mm  
)
```

```
[1] -0.6931225
```

Záporná hodnota potvrzuje klesající směr a její velikost ukazuje těsný vztah. Korelace však nevyjádří změnu tloušťky listu v milimetrech na 1 °C. K tomu použijeme známý lineární model.

5 První model používá jednu klimatickou informaci

Roční teplota je v tomto modelu jediným prediktorem.

```
mod_rocni_teplota <- lm(  
  formula = tloustka_listu_mm ~ teplota_rocni_C,
```

```
data = data_kridlatka
)

summary(object = mod_rocni_teploata)
```

```
Call:
lm(formula = tloustka_listu_mm ~ teplota_rocni_C, data = data_kridlatka)

Residuals:
    Min       1Q   Median       3Q      Max
-0.095017 -0.026242  0.003225  0.025530  0.091216

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.5105454  0.0115134   44.34  <2e-16 ***
teplota_rocni_C -0.0091332  0.0008462  -10.79  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04161 on 126 degrees of freedom
Multiple R-squared:  0.4804,    Adjusted R-squared:  0.4763
F-statistic: 116.5 on 1 and 126 DF,  p-value: < 2.2e-16
```

Co už umíme přečíst z výstupu?

Najděte ve výstupu řádek pro průměrnou roční teplotu a odpovězte:

1. Jaké znaménko má odhad koeficientu?
2. V jakých jednotkách koeficient interpretujeme?
3. Jakou změnu tloušťky očekává model při rozdílu 5 °C?

Koeficient průměrné roční teploty je -0.0091 mm na 1 °C. Záporné znaménko odpovídá klesající přímce v grafu: populace z místa teplejšího o 1 °C má podle modelu v průměru list tenčí přibližně o 0.0091 mm.

Při rozdílu 5 °C model odhaduje změnu

$$5 \times (-0.0091) = -0.046 \text{ mm.}$$

Tento výpočet porovnává dvě populace lišící se průměrnou roční teplotou původu o 5 °C.


Doplňující: údaj o popsání variability

Ve výstupu `summary()` je také $R^2 = 0.480$. Tato hodnota říká, že přímka s roční teplotou popisuje přibližně 48 % variability populačních průměrů tloušťky. R^2 samo nerozhoduje, který z několika modelů máme upřednostnit; jeho využití při porovnávání modelů patří do pozdější lekce.

5.1 Odpovídá přímka struktuře reziduí?


Po interpretaci koeficientu zkontrolujeme, zda v reziduích nezůstává zřetelné zakřivení nebo změna rozptylu:

```
plot(x = mod_rocni_teplota, which = 1)
```



Body by měly být rozptýlené kolem vodorovné nuly bez nápadného oblouku nebo trychtýře. Zde nevidíme výrazný systematický vzor, který by sám o sobě zpochybnil lineární popis.

Na závěr spojíme pozorované populace s trendem, který odhaduje jednoprediktorový model. Přímka ukazuje odhadovanou tloušťku pro jednotlivé roční teploty a šedý pás nejistotu průměrného trendu:



Obrázek 2: Pozorované populace a trend odhadnutý modelem s průměrnou roční teplotou.

6 Lineární model může skládat několik příspěvků

První model použil jako jediný prediktor průměrnou roční teplotu. V tabulce ale máme také maximum teploty nejteplejšího měsíce. Stejným známým postupem ověříme, jak souvisí s tloušťkou listu samo o sobě:

```
mod_max_teplota <- lm(
  formula = tloustka_listu_mm ~ teplota_max_C,
  data = data_kridlatka
)
```

```
summary(object = mod_max_teplota)
```

Call:

```
lm(formula = tloustka_listu_mm ~ teplota_max_C, data = data_kridlatka)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.087708	-0.026667	-0.007747	0.029279	0.119924

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.6509898	0.0247701	26.28	<2e-16 ***
teplota_max_C	-0.0095029	0.0009013	-10.54	<2e-16 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04207 on 126 degrees of freedom
Multiple R-squared: 0.4687, Adjusted R-squared: 0.4645
F-statistic: 111.2 on 1 and 126 DF, p-value: < 2.2e-16

Jak číst druhý jednoprediktorový model?

Najděte koeficient maximální teploty. Jaké má znaménko, v jakých jednotkách ho interpretujeme a jak se jeho otázka liší od modelu s průměrnou roční teplotou?


Model odhaduje změnu -0.0095 mm na zvýšení maxima nejteplejšího měsíce o 1 °C. Tento koeficient popisuje celkový vztah k maximální teplotě bez zohlednění průměrné roční teploty.



Obrázek 3: Pozorované populace a trend odhadnutý modelem s maximem teploty nejteplejšího měsíce.

Také u tohoto modelu zkontrolujeme, zda v reziduích nezůstává nápadné zakřivení nebo změna rozptylu:

```
plot(x = mod_max_teplota, which = 1)
```



Rezidua jsou rozptýlená kolem nuly bez výrazného oblouku; lineární trend je proto pro tento jednoduchý popis přijatelný.

Oba jednoprediktorové modely ukazují klesající klimatický trend, ale každý používá pouze jednu část teplotního režimu a kolem jeho přímky zůstává značná variabilita. Chceme proto odhadovat tloušťku listu podle průměrné roční i maximální teploty současně. Ve formuli přidáme druhý prediktor znaménkem +:

```
mod_dve_tploty <- lm(
  formula = tloustka_listu_mm ~ teplota_rocni_C + teplota_max_C,
  data = data_kridlatka
)

summary(object = mod_dve_tploty)
```

```
Call:
lm(formula = tloustka_listu_mm ~ teplota_rocni_C + teplota_max_C,
    data = data_kridlatka)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.081384 -0.024798 -0.003083  0.025821  0.105537
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.589936   0.030071  19.618 < 2e-16 ***
teplota_rocni_C -0.005279   0.001585  -3.330  0.00114 **
teplota_max_C  -0.004751   0.001670  -2.845  0.00519 **
```

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04048 on 125 degrees of freedom
Multiple R-squared:  0.512, Adjusted R-squared:  0.5042
F-statistic: 65.58 on 2 and 125 DF,  p-value: < 2.2e-16

```

Znaménko + ve formuli říká, že model odhaduje příspěvek **obou prediktorů současně**. Neznamená, že se dvě naměřené teploty prostě sečtou. Koeficient roční teploty popisuje její vztah k tloušťce při stejném maximu nejteplejšího měsíce; koeficient maxima popisuje jeho vztah při stejné roční teplotě.

Které tři parametry model odhadl?

Ve výstupu `summary()` najdete tři parametry modelu: výchozí hodnotu a oba teplotní koeficienty. Odhadnutý sklon vyjadřuje změnu odezvy na jednotku prediktoru. Jak byste každý z nich popsali jednou větou a v jakých jednotkách?

Textový zápis odhadnuté hodnoty má tři části:

odhadnutá tloušťka listu = výchozí tloušťka
 + sklon roční teploty × roční teplota
 + sklon maxima × maximum nejteplejšího měsíce .

Konkrétní dosazení ukážeme na 29. řádku výukové tabulky:

```

bod_priklad <- data_kridlatka[
  29,
  c("populace", "teplota_rocni_C", "teplota_max_C")
]

bod_priklad

```

	populace	teplota_rocni_C	teplota_max_C
29	CN35	15.25	29.85

Příklad ukazuje skutečnou populaci CN35 s průměrnou roční teplotou 15.25 °C a maximem nejteplejšího měsíce 29.85 °C. Dosazení odhadnutých parametrů a pozorovaných teplot je

$$\begin{aligned}
 \widehat{\text{tloušťka}} &= 0.5899 + (-0.0053) \times 15.25 \\
 &\quad + (-0.0048) \times 29.85 \\
 &= 0.5899 - 0.0805 - 0.1418 \\
 &= 0.368 \text{ mm.}
 \end{aligned}$$

Stejnou strukturu zapisujeme pro dva prediktory obecně jako

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i,$$

a pro p prediktorů jako

$$Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_{ji} + \varepsilon_i.$$

Y_i je tloušťka listu populace i ; β_0 je výchozí hodnota; β_j je koeficient prediktoru j ; X_{ji} je hodnota prediktoru j u populace i ; p je počet prediktorů; j označuje konkrétní prediktor a ε_i odchylku populace od modelu. Každý koeficient má **podmíněný význam**: β_1 porovnává populace lišící se v X_1 při stejných hodnotách ostatních prediktorů.

7 Klimatické proměnné nenesou nezávislé informace

Osm klimatických proměnných ve výukové tabulce popisuje různé části stejného klimatu. Teplé oblasti například často mívají vysokou průměrnou roční teplotu i vysoké maximum nejteplejšího měsíce. Korelační matice ukáže všechny dvojice současně.

Které dvojice budou silně souviset?

Před zobrazením matice vyberte dvě klimatické proměnné, u nichž očekáváte silnou kladnou korelaci. Který biologický nebo fyzikální vztah váš odhad podporuje?

Doplňující: kód pro korelační matici

```
# Vybereme pouze číselné klimatické proměnné
klima <- data_kridlatka[c(
  "teplota_rocni_C", "teplota_sezonnost", "teplota_max_C",
  "teplota_min_C", "srazky_rocni_mm", "srazky_nejvlhci_mesic_mm",
  "srazky_nejsussi_mesic_mm", "srazky_sezonnost"
)]

# Krátké české názvy zlepší čitelnost matice
names(klima) <- c(
  "Roční teplota", "Sezónnost teploty", "Nejteplejší měsíc",
  "Nejchladnější měsíc", "Roční srážky", "Nejvlhčí měsíc",
  "Nejsušší měsíc", "Sezónnost srážek"
)


# Pearsonova korelace shrnuje směr a sílu každého páru
matice_korelaci <- cor(x = klima)
```

```

# Dolní trojúhelník ukáže koeficienty bez zrcadlového opakování.
# Ponecháme pořadí proměnných z tabulky; stejné pořadí má matice na snímku.
# Modrá značí kladnou, bílá nulovou a oranžová zápornou korelaci.
ggcorrplot::ggcorrplot(
  corr = matice_korelaci,
  type = "lower",
  lab = TRUE,
  hc.order = FALSE,
  colors = c("#B4461B", "#FFFFFF", "#007C91"),
  outline.color = "white"
)


```

Kód vybírá osm klimatických sloupců, zkracuje jejich popisky, počítá Pearsonovy korelace a předává výslednou matici funkci `ggcorrplot()`. Proměnné jsou ve stejném pořadí jako v prezentaci; zobrazená je pouze polovina souměrné matice.



Obrázek 4: Korelační matice osmi klimatických prediktorů. Čísla jsou Pearsonovy korelační koeficienty.

Průměrná roční teplota a maximum nejteplejšího měsíce koreluje 0.855. Obě proměnné proto nesou překrývající se informaci o teplotním režimu populace.



Obrázek 5: Průměrná roční teplota a maximum nejteplejšího měsíce nesou silně překrývající se informaci.

8 Porovnání modelů

Jednoprediktorový model shrnuje celkový vztah tloušťky listu k průměrné roční teplotě. Model se dvěma teplotami rozděluje tuto klimatickou informaci mezi dva související prediktory. Porovnáním nesoutěžíme o automaticky „lepší“ model; sledujeme, jak přidání překrývající se informace mění otázku, odhad a jeho nejistotu. Oba modely používají stejných 128 populací, takže rozdíl nevzniká změnou analyzovaných řádků.

```
# Zobrazíme celou tabulku koeficientů každého modelu
coef(object = summary(object = mod_rocni_teplota))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.510545418	0.01151336	44.34376	9.711812e-79
teplota_rocni_C	-0.009133159	0.00084616	-10.79365	1.237814e-19

```
coef(object = summary(object = mod_dve_teploty))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.589935700	0.030071033	19.618073	5.666443e-40
teplota_rocni_C	-0.005278927	0.001585346	-3.329828	1.142457e-03
teplota_max_C	-0.004750850	0.001669974	-2.844864	5.193218e-03

V každé tabulce najdeme řádek `teplota_rocni_C`. Sloupec `Estimate` obsahuje odhad koeficientu a sloupec `Std. Error` jeho standardní chybu. Nemusíme tedy hodnoty složité vybírat kódem; pro výukové srovnání je přehlednější číst oba sloupce přímo z úplných tabulek.

V prvním modelu koeficient průměrné roční teploty zahrnuje veškerou informaci, kterou tato proměnná nese o společném teplotním gradientu. Po přidání maxima nejteplejšího měsíce se ptáme na užší vztah: jak se liší tloušťka mezi populacemi se stejným maximem, ale odlišnou průměrnou roční teplotou.

Odhad se proto změnil z -0.00913 na -0.00528 mm na 1°C . Standardní chyba současně vzrostla z 0.00085 na 0.00159 . Korelované prediktory poskytují málo populací, které se výrazně liší v jedné teplotě při téměř stejné druhé teplotě. Samostatné koeficienty se proto oddělují s větší nejistotou, přestože model lze bez problému fitovat.

Doplňující: korelované prediktory mohou vytvářet nestabilní koeficienty

Právě zobrazené tabulky ukázaly, že když dva prediktory nesou téměř stejnou informaci, model má málo pozorování, která by je dokázala od sebe oddělit. Malá změna dat nebo přidání několika populací pak může výrazně změnit jejich jednotlivé koeficienty, znaménka i standardní chyby. Proto je nečteme jako dvě samostatné biologické odpovědi bez ohledu na jejich překryv.

Pomocným ukazatelem bývá VIF (*variance inflation factor*), který shrnuje, nakolik je nejistota koeficientu zvětšena překryvem s ostatními prediktory. VIF ale nemá univerzální hranici, po jejímž překročení musíme proměnnou automaticky smazat. Nejdříve se vracíme k biologické otázce, rozsahu společně pozorovaných hodnot a tomu, zda chceme samostatně interpretovat koeficienty, nebo předpovídat podporované kombinace.

Doplňující: porovnání není výběr nejlepšího modelu

Zde porovnáváme koeficienty, protože chceme pochopit, jak přidání souvisejícího prediktoru změnilo statistickou otázku. O výběru modelu ale nerozhodujeme. V dalších lekcích budeme pracovat s principem úspornosti: mezi biologicky smysluplnými modely budeme hledat takový, který popisuje data dostatečně dobře bez zbytečné složitosti. K tomu nestačí vybrat model s nejvyšším R^2 .


Jakou otázku zodpovídá koeficient roční teploty?

Porovnává dvě populace se stejným maximem nejteplejšího měsíce, které se liší průměrnou roční teplotou. Najděte v bodovém grafu oblast, kde data takové srovnání skutečně podporují.

8.1 Změnil druhý prediktor také strukturu reziduí?


Stejnou diagnostiku použijeme u obou modelů. Každý graf vytvoříme samostatně, aby jeho kód neměnil nastavení dalších grafů.

```
plot(x = mod_rocni_teplota, which = 1)
```



Obrázek 6: Rezidua modelu pouze s průměrnou roční teplotou.

```
plot(x = mod_dve_teploty, which = 1)
```




Obrázek 7: Rezidua modelu s průměrnou roční a maximální teplotou.

V obou grafech hledáme zakřivení nebo systematickou změnu rozptylu. Přidání druhé teploty mírně mění odhady, ale nevytváří nový výrazný vzor reziduí. Porovnání koeficientů proto interpretujeme jako změnu podmíněné otázky a její nejistoty, nikoli jako opravu zjevně nevyhovujícího prvního modelu.

9 Původ populací mění příběh vztahu

Jeden lineární model může obsahovat několik číselných prediktorů, několik kategoriálních prediktorů nebo jejich kombinaci. Typ prediktoru nemění základní princip: znaménkem + přidáváme do stejného modelu další informaci.

Rozlišíme pozorované populace podle původu, zatím bez modelových přímek:



Obrázek 8: Pozorované populace rozlišené podle původního a zavlečeného areálu. Jeden bod je jedna zdrojová populace.

Jak se liší obě skupiny?

Ve kterých teplotách pozorujeme původní a zavlečené populace? Která skupina má při podobné teplotě výše položené body? Je klesající vztah stejně zřetelný uvnitř obou skupin jako v celém souboru?

Původní populace pocházejí převážně z teplejších míst a současně mají tenčí listy. Celkový vztah napříč všemi populacemi proto spojuje rozdíl mezi skupinami se vztahy uvnitř skupin. K roční teplotě přidáme kategoriální prediktor původu:

```
mod_puvod <- lm(  
  formula = tloustka_listu_mm ~ puvod + teplota_rocni_C,  
  data = data_kridlatka  
)  
  
summary(object = mod_puvod)
```

```
Call:  
lm(formula = tloustka_listu_mm ~ puvod + teplota_rocni_C, data = data_kridlatka)  
  
Residuals:  
      Min       1Q   Median       3Q      Max   
-0.089547 -0.017475 -0.003619  0.009723  0.108468
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.311427	0.021253	14.653	<2e-16 ***
puvodZavleceny	0.108947	0.010651	10.228	<2e-16 ***
teplota_rocni_C	0.001491	0.001213	1.229	0.221

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.03082 on 125 degrees of freedom


Multiple R-squared: 0.7172, Adjusted R-squared: 0.7126

F-statistic: 158.5 on 2 and 125 DF, p-value: < 2.2e-16

Jak číst model s teplotou a původem?

Která skupina je ve výstupu referenční? Najděte společný sklon roční teploty a posun zavlečených populací vůči původním. Jak byste oba koeficienty popsali v biologických jednotkách?

Znaménko + vytváří aditivní model. Koeficient původu posouvá jednu skupinu vůči druhé, zatímco koeficient roční teploty určuje společný sklon obou skupin.




Obrázek 9: Body jsou pozorované populace. Rovnoběžné přímky jsou odhady aditivního modelu se společným sklonem roční teploty a rozdílnou výchozí úrovní původu.

Rovnoběžné přímky zobrazují aditivní model: při každé teplotě je modelový rozdíl mezi skupinami stejný a obě skupiny mají společný sklon.

Doplňující: co kdyby skupiny neměly společný sklon?

Graf může vyvolat otázku, zda se vztah mezi roční teplotou a tloušťkou listu liší podle původu populace. Takovou otázku řeší interakce prediktorů: dovolila by každé skupině jiný sklon, takže přímky by nemusely být rovnoběžné. Interakce patří do následující lekce; zde ji nefitujeme ani neinterpretujeme.




Obrázek 10: Schematické porovnání. Aditivní model vyžaduje společný sklon; interakce by umožnila rozdílné sklony skupin.

Levý panel ukazuje předpoklad našeho aditivního modelu. Pravý panel není výsledek další analýzy; pouze ukazuje tvar, který by model s interakcí mohl povolit.

9.1 Kontrola modelu s teplotou a původem

```
plot(x = mod_puvod, which = 1)
```




V grafu hledáme zakřivení nebo změnu rozptylu reziduí. Diagnostický graf zde neukazuje důvod měnit předem zvolenou strukturu modelu.

Doplňující: které populace mají na model velký vliv?

Cookova vzdálenost doplňuje kontrolu reziduí o otázku, zda některá populace výrazně ovlivňuje odhadnuté koeficienty:

```
plot(x = mod_puvod, which = 4)
```



Označená populace není automaticky chybná a nemažeme ji pouze kvůli vysoké hodnotě. Ověříme její zdrojová data a zkoumáme, proč má na model velký vliv.

Po přidání původu se koeficient roční teploty změní z -0.00913 na 0.00149 mm na 1°C . První model popisuje celkový vztah napříč oblastmi. Druhý porovnává populace stejného statusu původu. Ani jeden koeficient není „ten jediný pravý“; odpovídají na jiné otázky.

Doplňující: přidat další prediktor není vždy správná kontrola

Další prediktor má smysl přidat podle biologické otázky a představy o tom, jak proměnné vznikly. Při konfundování ovlivňuje třetí proměnná prediktor i odezvu, takže jejich celková asociace míjí více cest. Zohlednění takové proměnné může otázku zpřesnit.

Jiná situace nastane, když doplníme **prostřední článek** mechanismu. Pokud hnojení mění obsah dusíku v listu a ten následně růst, kontrola dusíku odstraní část účinku hnojení a položí užší otázku o přímé cestě. Ještě opatrnější musíme být u **společného následku** dvou proměnných: výběr pouze přeživších jedinců může vytvořit asociaci mezi vlastnostmi, které ovlivňují přežití, i když spolu v původní populaci nesouvisely.

Pravidlo „přidejte do modelu vše, co máte“ proto nechrání automaticky před zkreslením. Model popisuje podmíněné vztahy; kauzální význam vyžaduje navíc znalost uspořádání studie a biologického mechanismu.

10 Jak model odhadne tloušťku při stejné teplotě

Model použijeme k výpočtu dvou **bodových odhadů**: odhadnuté průměrné tloušťky původních a zavlečených populací při stejné roční teplotě. Bodové odhady udávají dvě modelové hodnoty, ale samy nevyjadřují jejich nejistotu.

Původní areál je referenční skupina. Pro smysluplné porovnání potřebujeme teplotu, při které máme data z obou areálů. Rozdělíme populace podle původu, vypočítáme rozsah teplot v každé skupině a zobrazíme jejich společnou část:

```
data_puvodni <- data_kridlatka[
  data_kridlatka$puvod == "Puvodni",
]
data_zavlecene <- data_kridlatka[
  data_kridlatka$puvod == "Zavleceeny",
]

rozsah_puvodni <- range(x = data_puvodni$teplota_rocni_C)
rozsah_zavleceny <- range(x = data_zavlecene$teplota_rocni_C)

dolni_spolecna <- max(rozsah_puvodni[1], rozsah_zavleceny[1])
horni_spolecna <- min(rozsah_puvodni[2], rozsah_zavleceny[2])

c(dolni_spolecna, horni_spolecna)
```

```
[1] 12.15 16.35
```

Společný rozsah je přibližně 12.2 až 16.4 °C. Zvolíme hodnotu uvnitř tohoto intervalu:

```
teplota_pro_porovnani <- 14
teplota_pro_porovnani
```

```
[1] 14
```

Vytvoříme dva řádky, které se liší pouze původem. Jde o modelové scénáře při stejné roční teplotě, nikoli o nové naměřené populace:

```

scenare_modelu <- data.frame(
  puvod = factor(
    x = c("Puvodni", "Zavleceeny"),
    levels = levels(x = data_kridlatka$puvod)
  ),
  teplota_rocni_C = c(
    teplota_pro_porovnani,
    teplota_pro_porovnani
  )
)

scenare_modelu

```

	puvod	teplota_rocni_C
1	Puvodni	14
2	Zavleceeny	14

Model skládá odhadnutou tloušťku ze tří snadno pojmenovatelných částí:

odhadnutá tloušťka = výchozí tloušťka původní populace + příspěvek zavlečeného areálu + příspěvek roční teploty .

U původní populace je skupinový příspěvek nulový, protože jde o referenční skupinu. Plně rozepsané dosazení pro první řádek a následné vyčíslení jednotlivých příspěvků je

$$\begin{aligned}
 0.3114 + 0 + (0.00149) \times 14 &= 0.3114 + 0 + (0.0209) \\
 &= 0.332 \text{ mm.}
 \end{aligned}$$

U zavlečené populace se přidá koeficient `puvodZavleceeny`:

$$\begin{aligned}
 0.3114 + (0.1089) + (0.00149) \times 14 &= 0.3114 + (0.1089) + (0.0209) \\
 &= 0.441 \text{ mm.}
 \end{aligned}$$

Ruční výpočet zkontrolujeme funkcí `predict()`. Výsledky přidáme do stejné dvouřádkové tabulky:

```

scenare_modelu$odhad_mm <- predict(
  object = mod_puvod,
  newdata = scenare_modelu
)

scenare_modelu

```

	puvod	teplota_rocni_C	odhad_mm
1	Puvodni	14	0.3323001
2	Zavleceeny	14	0.4412474

Rozdíl obou odhadů při stejné teplotě je 0.109 mm. Je přesně roven koeficientu `puvodZavleceeny`, protože ostatní části rovnice jsou v obou scénářích stejné.

Tabulka obsahuje dva bodové odhady, ale neukazuje, s jakou přesností je model určil. K vyjádření přesnosti potřebujeme intervaly spolehlivosti.

Abstraktní zápis pro původní populaci je

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

zatímco pro zavlečenou populaci přidáme skupinový koeficient:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_{\text{zavlečený}} + \hat{\beta}_1 X_i.$$

$\hat{Y}_i$ je predikovaná tloušťka populace i , X_i její průměrná roční teplota, $\hat{\beta}_0$ výchozí hodnota původní skupiny, $\hat{\beta}_{\text{zavlečený}}$ rozdíl zavlečené skupiny při stejné teplotě a $\hat{\beta}_1$ změna s průměrnou roční teplotou při stejném původu.

11 Stejné porovnání doplníme o nejistotu

V předchozí části jsme při 14 °C získali jeden bodový odhad pro původní a jeden pro zavlečené populace. K oběma doplníme nejistotu. Pro pochopení, proč potřebujeme modelové odhady při stejné teplotě, je porovnáme s prostými průměry naměřené tloušťky. Každou skupinu vybereme přímo a její průměr vypočítáme zvlášť:

```
prumer_puvodni <- mean(  
  x = data_kridlatka$tloustka_listu_mm[  
    data_kridlatka$puvod == "Puvodni"  
  ]  
)  
prumer_puvodni
```

```
[1] 0.3370428
```

```
prumer_zavleceeny <- mean(  
  x = data_kridlatka$tloustka_listu_mm[  
    data_kridlatka$puvod == "Zavleceeny"  
  ]  
)  
prumer_zavleceeny
```

```
[1] 0.4347821
```

Tyto dva průměry popisují skutečně pozorované skupiny. Skupiny se však liší také rozložením ročních teplot: původní populace pocházejí převážně z teplejších míst. Rozdíl prostých průměrů proto spojuje rozdíl původu s rozdílem klimatu. Pokud chceme interpretovat koeficient původu v aditivním modelu, musíme skupiny porovnat při stejné roční teplotě.

V předchozí části jsme pro obě skupiny vypočítali společný teplotní rozsah a zvolili 14 °C uvnitř tohoto překryvu. Porovnání tak leží v oblasti podložené pozorováními původních i zavlečených populací.

Funkci `emmeans()` známe ze srovnání kategorií. Zde jí navíc řekneme, při které hodnotě číselného prediktoru má skupiny porovnat. Vrátí stejné bodové odhady, které jsme ručně sestavili a ověřili funkcí `predict()`, a navíc jejich nejistotu:

```
modelove_prumery <- emmeans::emmeans(  
  object = mod_puvod,  
  specs = ~ puvod,  
  at = list(teplota_rocni_C = teplota_pro_porovnani)  
)
```


modelove_prumery

puvod	emmean	SE	df	lower.CL	upper.CL
Puvodni	0.332	0.00567	125	0.321	0.344
Zavleceeny	0.441	0.00638	125	0.429	0.454

Confidence level used: 0.95

Modelové průměry se od prostých průměrů liší, protože nyní držíme roční teplotu stejnou. Sloupce `lower.CL` a `upper.CL` jsou meze 95% intervalu spolehlivosti pro **průměrnou modelovou hodnotu**, nikoli pro nový jednotlivý populační průměr.

V grafu jsou tyto dva modelové průměry zvýrazněné na rovnoběžných přímkách. Svislé úsečky zobrazují jejich intervaly spolehlivosti:



Obrázek 11: Modelové průměry původních a zavlečených populací při stejné roční teplotě. Svislé úsečky jsou 95% intervaly spolehlivosti.

Doplňující: jak bezpečně predikovat z více prediktorů

```
nova_data <- data.frame(  
  puvod = factor(  
    x = c("Zavleceeny", "Puvodni"),  
    levels = levels(x = data_kridlatka$puvod)  
  ),  
  teplota_rocni_C = c(14, 14)  
)
```

```
predict(object = mod_puvod, newdata = nova_data, interval = "confidence")
```


```
      fit      lwr      upr
1 0.4412474 0.4286232 0.4538716
2 0.3323001 0.3210759 0.3435244
```

Datový rámec `newdata` musí obsahovat každý prediktor modelu, stejné názvy, jednotky a úrovně faktorů. U modelu se dvěma teplotami navíc nestačí, aby byla každá hodnota samostatně v pozorovaném rozsahu. Jejich **kombinace** musí odpovídat reálnému klimatu.

Predikce není stavebnice libovolných hodnot

Kombinace velmi nízké roční teploty a velmi vysokého maxima nejteplejšího měsíce může ležet mimo společný mrak dat. Model číslo vypočítá, ale data takovou klimatickou situaci nemusí podporovat.

	teplota_rocni_C	teplota_max_C	podpora	fit	lwr	upr
1	14	29	Podporovaný	0.3782561	0.3703263	0.3861858
2	7	33	Nepodporovaný	0.3962052	0.3591626	0.4332477



Obrázek 12: Podporovaný scénář leží uvnitř společného mraku obou teplot; nepodporovaný scénář skládá dvě jednotlivě možné, ale společně nepozorované hodnoty.

Oba řádky mají interval spolehlivosti pro modelový průměr. Model vypočítá i nepodporovaný oranžový bod, protože jeho dvě hodnoty jsou číselně platné. V datech však taková kombinace

prakticky chybí, takže její věcná opora je slabá; interval z `predict()` tuto chybějící klimatickou analogii sám nevaruje.

12 Záleží u testu na pořadí prediktorů?

V předchozích lekcích jsme testovali, zda je koeficient slučitelný s nulou, a funkcí `anova()` jsme pokládali celkovou otázku o rozdílech mezi skupinami. U modelu s několika prediktory musíme rozlišit **test koeficientu** a **sekvenční test prediktoru**. Oba mohou uvádět p-hodnotu, ale odpovídají na jinak formulované otázky.

Vytvoříme druhý zápis stejného modelu. Obsahuje stejné dva prediktory a liší se pouze jejich pořadím ve formuli:

```
# Stejně prediktory zapíšeme v opačném pořadí
mod_dve_teploty_opacne <- lm(
  formula = tloustka_listu_mm ~ teplota_max_C + teplota_rocni_C,
  data = data_kridlatka
)
```

12.1 Co se změnil v tabulce koeficientů?

Tabulka `summary()` testuje u každého koeficientu nulovou hypotézu, že je při zohlednění ostatních prediktorů roven nule. V obou zápisech porovnáme odhady, standardní chyby, t-statistiky a p-hodnoty:

```
coef(object = summary(object = mod_dve_teploty))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.589935700	0.030071033	19.618073	5.666443e-40
teplota_rocni_C	-0.005278927	0.001585346	-3.329828	1.142457e-03
teplota_max_C	-0.004750850	0.001669974	-2.844864	5.193218e-03

```
coef(object = summary(object = mod_dve_teploty_opacne))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.589935700	0.030071033	19.618073	5.666443e-40
teplota_max_C	-0.004750850	0.001669974	-2.844864	5.193218e-03
teplota_rocni_C	-0.005278927	0.001585346	-3.329828	1.142457e-03

Co se po obrácení pořadí nezměnilo?

Porovnejte řádky `teplota_rocni_C` a `teplota_max_C` v obou tabulkách. Zůstaly stejné sloupce `Estimate`, `Std. Error`, `t value` a `Pr(>|t|)`?

Změnilo se pouze pořadí řádků. Oba zápisy mají stejné koeficienty a stejné testy koeficientů, protože každý koeficient stále popisuje vztah při stejné hodnotě druhého prediktoru. Stejně jsou také odhadnuté hodnoty a residua:

```
all.equal(
  target = fitted(object = mod_dve_teploty),
  current = fitted(object = mod_dve_teploty_opacne)
)
```

```
[1] TRUE
```

```
all.equal(
  target = residuals(object = mod_dve_teploty),
  current = residuals(object = mod_dve_teploty_opacne)
)
```

```
[1] TRUE
```

Výsledek `TRUE` potvrzuje, že jde o tentýž fitovaný model. Nemusíme proto opakovat diagnostiku reziduí.

12.2 Sekvenční analýza rozptylu klade otázky zleva doprava

Základní `anova()` v R používá **sekvenční testy**. První řádek se ptá, kolik variability popíše první prediktor oproti modelu bez klimatického prediktoru. Druhý řádek se ptá, kolik další informace přidá druhý prediktor po zohlednění prvního.

Co očekáváte od dvou tabulek?

Klimatické prediktory jsou silně korelované. Který prediktor převezme jejich společnou informaci, když jej zapíšeme jako první?

```
# Roční teplota vstupuje do sekvenčního testu jako první
anova(object = mod_dve_teploty)
```

Analysis of Variance Table

```
Response: tloustka_listu_mm
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
teplota_rocni_C	1	0.201696	0.201696	123.0616	< 2.2e-16 ***
teplota_max_C	1	0.013265	0.013265	8.0933	0.005193 **
Residuals	125	0.204873	0.001639		

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Maximální teplota vstupuje do sekvenčního testu jako první
anova(object = mod_dve_teploty_opacne)
```

Analysis of Variance Table

```
Response: tloustka_listu_mm
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
teplota_max_C	1	0.196788	0.196788	120.067	< 2.2e-16 ***
teplota_rocni_C	1	0.018173	0.018173	11.088	0.001142 **
Residuals	125	0.204873	0.001639		

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Když je první roční teplota, její řádek převezme také velkou část informace sdílené s maximální teplotou. Řádek maxima nejteplejšího měsíce zachycuje pouze to, co maximum přidá nad rámec roční teploty. Při opačném pořadí převezme sdílenou část maximum a řádek roční teploty zachycuje její dodatečný příspěvek.

Rozdíl je v tabulkách konkrétní. P-hodnota sekvenčního testu roční teploty je při jejím prvním místě $<1e-16$, ale po předchozím zohlednění maximální teploty 0.00114. U maximální teploty se p-hodnota změní z $<1e-16$ při prvním místě na 0.00519 po zohlednění roční teploty.

Proto se mezi tabulkami mění sekvenční součty čtverců, F-statistiky a p-hodnoty. Nemění se však data ani fitovaný model. P-hodnota koeficientu v `summary()` odpovídá podmíněné otázce „přidává tento prediktor informaci při zahrnutí druhého prediktoru?“, v tomto modelu s jedním stupněm volnosti na prediktor se proto shoduje se sekvenčním testem daného prediktoru tehdy, když je zapsán jako druhý.

Z předchozích lekcí známe obecný význam vysvětlené a nevysvětlené variability, součtů čtverců a F-statistiky. Zde je používáme k pochopení důsledku pořadí prediktorů. K podrobnějšímu rozdělení sdílené variability mezi několik prediktorů a k dalším způsobům testování modelových členů se vrátíme v dalších lekcích.

Co je hlavní zpráva?

Pořadí prediktorů ve formuli mění **p-hodnoty sekvenčních testů** z `anova()`, ale nemění p-hodnoty koeficientů v `summary()`. Přesouvání prediktorů ve formuli proto není způsob, jak vybrat vhodné prediktory nebo získat příznivější výsledek.

Doplňující: testy nezávislé na pořadí prediktorů

Pokud chceme každý prediktor testovat po zohlednění všech ostatních prediktorů v aditivním modelu, můžeme použít testy typu II z funkce `car::Anova()`. Na rozdíl od sekvenčních testů z `anova()` nepřidělují sdílenou informaci podle pořadí členů ve formuli.

```
# Každý prediktor testujeme po zohlednění druhého prediktoru
car::Anova(
  mod = mod_dve_tploty,
  type = 2
)
```

Anova Table (Type II tests)

```
Response: tloustka_listu_mm
              Sum Sq Df F value    Pr(>F)
teplota_rocni_C 0.018173  1 11.0878 0.001142 **
teplota_max_C   0.013265  1  8.0933 0.005193 **
Residuals      0.204873 125
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Obrácení pořadí ve formuli odpověď nezmění
car::Anova(
  mod = mod_dve_tploty_opacne,
  type = 2
)
```

Anova Table (Type II tests)

```
Response: tloustka_listu_mm
              Sum Sq Df F value    Pr(>F)
teplota_max_C   0.013265  1  8.0933 0.005193 **
teplota_rocni_C 0.018173  1 11.0878 0.001142 **
Residuals      0.204873 125
```

```
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Řádky se v tabulkách objeví v pořadí podle formule, ale součet čtverců, F-statistika a p-hodnota každého prediktoru zůstávají stejné. V tomto aditivním modelu má každý číselný prediktor jeden stupeň volnosti, takže jeho test typu II odpovídá testu příslušného koeficientu v `summary()`; platí $F = t^2$.

Testy typu II jsou vhodné pro náš aditivní model bez interakce. U modelů s interakcemi je nejprve potřeba přesně určit věcnou hypotézu; automatická volba typu testu ji nenahradí.

12.3 Výběr prediktorů patří do dalších lekcí

Výběr prediktorů budeme formulovat jako porovnání předem smysluplných kandidátních modelů. V příštích lekcích využijeme princip úspornosti a také AIC, které zohledňuje shodu modelu s daty i počet jeho parametrů. Takový postup poskytuje pro výběr modelu lepší oporu než měnění pořadí prediktorů nebo hledání nejmenší p-hodnoty.

13 Jak postupovat u modelu s více prediktory

1. Začněte biologickou otázkou a určete jednotku pozorování.
2. Prohlédněte vztah odezvy ke každému prediktoru i vztahy mezi prediktory.
3. Porovnáváné modely fitujte na stejných řádcích.
4. Přeložte každý koeficient do věty „při stejných hodnotách ostatních prediktorů“.
5. Porovnejte odhady i jejich nejistotu, nejen p-hodnoty.
6. Rozlište test koeficientu od sekvenčního testu a u sekvenčního testu zdůvodněte pořadí prediktorů.
7. Predikujte pouze pro podporované kombinace hodnot.
8. Zkontrolujte rezidua a vlivná pozorování; nemažte je automaticky.

Tento postup není jednorázový seznam na konci analýzy. U každého nového modelu se vracíme k interpretaci koeficientů, kontrole reziduí a vlivných pozorování, jak jsme ukázali u modelů výše.

14 Společná zahrada neznamená náhodně přiřazené klima

Společná zahrada omezuje rozdíly v aktuálním prostředí, v němž byly listy změřeny. Neznamená však, že klima původu bylo náhodně přiřazeno. Původní a zavlečené populace mají odlišnou geografickou i evoluční historii. Naše jednoduché modely proto popisují asociace v těchto 128 populacích; samy nedokazují klimatickou adaptaci ani přímý příčinný účinek teploty.

15 Co si odnést

- Koeficient ve víceprediktorovém modelu je podmíněný na ostatní prediktory v rovnici.
- Přidání prediktoru může výrazně změnit velikost i směr vztahu, protože model odpovídá na novou otázku.
- Korelované klimatické prediktory ztěžují oddělení jejich samostatných příspěvků a mohou zvětšit nejistotu.
- Pořadí prediktorů mění p-hodnoty sekvenčních testů z `anova()`, nikoli p-hodnoty koeficientů v `summary()`.
- Predikce z víceprediktorového modelu potřebuje úplné a společně realistické kombinace hodnot.